

Chapitre 1 – La statistique descriptive

STT-1920 Méthodes statistiques

Département de mathématiques et de statistique



UNIVERSITÉ
LAVAL

1.1 Introduction

Pour commencer : 147 serpents nouveau-nés

Un chercheur étudie une espèce de serpents. Il a pesé 147 serpents à la naissance (en grammes). Voici le début de ses données :

33.90	34.87	34.49	34.16	35.14	34.10	34.41
33.10	35.59	35.20	34.35	33.87	35.18	34.54
35.71	34.74	36.42	34.68	34.05	34.76	35.49
35.44	36.03	34.19	35.49	35.30	34.26	35.36

⋮ (21 lignes en tout) ⋮

1. CENTRE ?
2. DISPERSION ?
3. ABERRANTES ?

Difficile d'y voir clair ! Quel est le poids « typique » ? Les poids varient-ils beaucoup ? Y a-t-il des valeurs étranges ?

⇒ Il faut résumer les données : c'est le rôle de la statistique descriptive.

21 LIGNES × 7 = 147 POIDS

Deux types de méthodes statistiques

Statistique descriptive = CHAPITRE 1

L'art de résumer un ensemble de données (tableaux, graphiques, quelques nombres) pour mettre en évidence l'information qu'elles contiennent.

Statistique inférentielle = CHAPITRES 3 À 7

L'art de tirer des conclusions au sujet d'une population à partir d'un échantillon provenant de cette population.

Plan du cours : chapitre 1, statistique descriptive; chapitre 2, probabilités (le modèle du hasard); chapitres 3 à 7, statistique inférentielle (intervalles de confiance, tests, ANOVA, régression, khi-deux).

INFÉRENCE : ÉCHANTILLON → POPULATION

Décrire avant d'analyser

Une bonne analyse statistique est **toujours** précédée d'un résumé des principales caractéristiques des données.

- **Mesures de tendance centrale**

- moyenne, médiane

- **Mesures de position**

- quantiles, quartiles

- **Mesures de dispersion**

- écart-type, coefficient de variation
- écart interquartile, étendue

- **Représentations graphiques**

- histogramme
- diagramme en boîte
- diagramme quantile-quantile
- diagrammes en bâtons et en pointes de tarte
- diagramme de dispersion

Tout cela se fait en quelques lignes avec le logiciel **R**.

1.2 Population, échantillon et variable

Exemple 1 : les serpents

Le chercheur a pesé 147 serpents nouveau-nés de l'espèce étudiée.

- **Population** : ensemble de **tous** les individus qui nous intéressent.
⇒ tous les serpents de cette espèce.
- **Échantillon** : les individus effectivement observés.
⇒ les 147 serpents pesés par le chercheur ($n = 147$).
- **Variable statistique** : caractéristique mesurée sur chaque individu.
⇒ le poids à la naissance (en g). On pourrait aussi mesurer la longueur, le sexe, ...



Une **statistique** est une quantité calculée à partir de l'échantillon (par exemple, la moyenne des 147 poids).

STATISTIQUE : $\bar{x}$ (ÉCHANTILLON)

PARAMÈTRE : μ (POPULATION)

Un jeu de données typique

Habituellement, on mesure **plusieurs variables** sur chaque individu. Une ligne = un individu; une colonne = une variable.

Exemple : suivi de grenouilles léopards dans trois étangs.

	<i>NOM.</i>	<i>NOM.</i>	<i>CONTINUE</i>	<i>DISCRÈTE</i>	<i>ORDINALE</i>
Grenouille	Étang	Sexe	Masse (g)	Nombre de parasites	Stade
1	A	F	23.4	3	adulte
2	A	M	18.9	0	juvénile
3	B	F	31.2	7	adulte
4	C	M	12.5	1	juvénile
5	B	M	27.8	2	adulte
⋮	⋮	⋮	⋮	⋮	⋮

UN INDIVIDU

Ces variables ne sont pas toutes de la même nature...

Les types de variables

Variables quantitatives

- **Continue** : toute valeur numérique d'un intervalle.
Ex. : masse, taille d'un plant.
- **Discrète** : valeurs isolées (souvent entières).
Ex. : nombre de parasites.

Variables qualitatives

- **Ordinale** : catégories (non numériques) ordonnées.
Ex. : stade (juvénile, adulte).
- **Nominale** : catégories sans ordre.
Ex. : étang, sexe, espèce.

Attention ! Un code numérique ne rend pas une variable quantitative : l'étang codé 1, 2, 3 ou le sexe codé 0/1 restent des variables **nominales**. Faire la moyenne de ces codes n'a aucun sens.

UN CODE N'EST PAS UNE MESURE !

QUIZ!

Quel est le type (quantitative continue ou discrète, qualitative ordinale ou nominale) de chacune des variables suivantes ?

- a) Le groupe sanguin (A, B, AB, O)
d'un donneur.

QUALITATIVE NOMINALE

- b) Le poids d'un loup à la naissance.

QUANTITATIVE CONTINUE

- c) Le stade d'un cancer (I, II, III, IV).

QUALITATIVE ORDINALE

- d) Le nombre de tomates d'un plant.

QUANTITATIVE DISCRÈTE

- e) La glycémie à jeun (en mmol/L).

QUANTITATIVE CONTINUE

- f) L'espèce d'un poisson capturé.

QUALITATIVE NOMINALE

- g) L'intensité d'une douleur (aucune, légère, modérée, sévère).

QUALITATIVE ORDINALE

ORDRE NATUREL ? → ORDINALE

ON COMPTE ? → DISCRÈTE

ON MESURE ? → CONTINUE


1.3 L'histogramme

Exemple 1 (suite) : données groupées

Pour voir la **forme** de la distribution d'une variable quantitative continue, on **groupe** d'abord les données en classes.

Poids (g)	Fréquence
(32.5, 33.0]	4
(33.0, 33.5]	5
(33.5, 34.0]	16
(34.0, 34.5]	30
(34.5, 35.0]	24
(35.0, 35.5]	29
(35.5, 36.0]	21
(36.0, 36.5]	11
(36.5, 37.0]	5
(37.0, 37.5]	1
(37.5, 38.0]	1
Total	147

(: EXCLU
]: INCLUS





Données **brutes** → données **groupées** (tableau de fréquences) → **histogramme**.

$$4 + 5 + 16 + 30 + 24 + 29 + 21 + 11 + 5 + 1 + 1 = 147$$



Le choix des classes est un peu arbitraire



- Trop de classes $\Rightarrow$ histogramme chaotique (classes presque vides).
- Trop peu de classes $\Rightarrow$ on ne voit plus la forme.
- En pratique : de 5 à 12 classes environ, selon n .

COMPROMIS !

Procédure pour tracer un histogramme

Soit un échantillon $x_1, \dots, x_n$.

1. On découpe l'étendue des données en ℓ classes $(c_0, c_1], (c_1, c_2], \dots, (c_{\ell-1}, c_\ell]$.
2. On compte la **fréquence absolue** f_j (nombre d'observations dans la classe j) et on calcule la **fréquence relative** f_j/n .
3. Sur chaque classe, on dessine un rectangle dont la **surface** est proportionnelle à la fréquence.

- **Classes de même largeur** : hauteur = fréquence absolue f_j (ou relative f_j/n).


- **Classes de largeurs inégales** : histogramme de **densité**, de hauteur
$$h_j = \frac{f_j/n}{c_j - c_{j-1}},$$
 de sorte que la surface du rectangle j vaut exactement f_j/n .

$$\text{SURFACE} = \text{LARGEUR} \times \text{HAUTEUR} = (c_j - c_{j-1}) \times h_j = f_j/n$$

Formes de distributions


L'histogramme permet de reconnaître la **forme** de la distribution ($n = 200$ dans chaque cas, données simulées) :

Symétrique




Pression systolique (mmHg)

Asymétrique à droite



Séjour à l'hôpital (jours)

Asymétrique à gauche



Durée de gestation (sem.)

On regarde aussi le nombre de « bosses » (**unimodale**, **bimodale**...) et la présence de valeurs isolées. Les poids des serpents : distribution unimodale et à peu près symétrique, « en cloche ».

Exemple 2 : classes de largeurs inégales


Pour calibrer un pulvérisateur agricole servant à appliquer un fongicide, on a mesuré le diamètre (en microns) de 155 gouttelettes. Les données ne nous sont fournies que sous forme groupée :

Diamètre (μm)	Fréquence	
(10, 20]	25	LARGEUR 10
(20, 30]	45	LARGEUR 10
(30, 40]	35	LARGEUR 10
(40, 60]	30	LARGEUR 20
(60, 100]	20	LARGEUR 40 !
Total	155	


Les deux dernières classes sont **plus larges** que les autres. Peut-on simplement prendre les fréquences comme hauteurs? **NON !**

Exemple 2 (suite) : attention aux classes inégales!

Hauteur = fréquence (à éviter) ✗



Histogramme de densité (correct) ✓



À gauche, la classe (60, 100] semble contenir presque autant de gouttelettes que (10, 20]... alors qu'elle est quatre fois plus large!

⇒ C'est la **surface** (et non la hauteur) qui doit représenter la fréquence. Avec des classes inégales, R trace automatiquement un histogramme de densité.

Exemple 2 (suite) : calcul des hauteurs

Classe	Fréquence f_j	Fréq. relative f_j/n	Largeur	Hauteur h_j
(10, 20]	25	0.1613	10	0.0161
(20, 30]	45	0.2903	10	0.0290
(30, 40]	35	0.2258	10	0.0226
(40, 60]	30	0.1935	20	0.0097
(60, 100]	20	0.1290	40	0.0032
Total	155	1	← SOMME DES $F_j/N = 1$	

Par exemple, pour la classe (40, 60] :

SURFACE (40, 60] :
 20×0.0097
 $\approx 0.1935 = F_4/N$

$$\frac{f_4}{n} = \frac{30}{155} = 0.1935 \quad \Rightarrow \quad h_4 = \frac{0.1935}{60 - 40} = 0.0097.$$

La surface totale de l'histogramme de densité vaut 1.

QUIZ!

Exemple 2 (gouttelettes du pulvérisateur).

- Quelle proportion des gouttelettes ont un diamètre entre 20 et 40 μm ?
Comment la lit-on sur l'histogramme de densité?


$$(45 + 35)/155 = 80/155 = 0.516, \text{ SOIT } 51.6 \%$$

$$= \text{SURFACE AU-DESSUS DE } (20, 40] : 10 \times 0.0290 + 10 \times 0.0226$$

- Sur un histogramme de densité, que vaut la surface totale des rectangles?
La somme des hauteurs a-t-elle une interprétation?

SURFACE TOTALE = 1 (100 %)

**SOMME DES HAUTEURS : PAS D'INTERPRÉTATION
(DÉPEND DES LARGEURS DES CLASSES)**



1.4 La moyenne et l'écart-type

Moyenne et écart-type échantillonnaires

Moyenne échantillonnale (mesure de tendance centrale)

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n} = \frac{1}{n} \sum_{i=1}^n x_i \quad \bar{x}: \text{« X BARRE »}$$

Écart-type échantillonnal (mesure de dispersion)

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2} \quad (s^2 = \text{variance échantillonnale})$$


n-1 : DEGRÉS DE LIBERTÉ

s est la **distance typique** entre les observations et leur moyenne, dans les mêmes unités que les données. (Pourquoi $n - 1$? Voir chapitre 3.)

Exemple 3 : calcul à la main

On a pesé 5 souris de laboratoire (en g) : 22 25 19 24 20.

$$\bar{x} = \frac{22 + 25 + 19 + 24 + 20}{5} = \frac{110}{5} = 22 \text{ g.}$$



x_i	22	25	19	24	20	Somme
$x_i - \bar{x}$	0	3	-3	2	-2	0
$(x_i - \bar{x})^2$	0	9	9	4	4	26

$$s^2 = \frac{26}{5 - 1} = 6.5 \text{ g}^2$$

UNITÉS AU CARRÉ !

et $s = \sqrt{6.5} = 2.55 \text{ g.}$ RETOUR AUX GRAMMES

Remarque : la somme des écarts $x_i - \bar{x}$ vaut toujours 0. C'est pourquoi on les met au carré avant de les additionner.

FORMULE DE CALCUL (PLUS RAPIDE À LA MAIN)

$$s^2 = \frac{\sum x_i^2 - N\bar{x}^2}{N-1}$$

EXEMPLE 3 :

$$\sum x_i^2 = 484 + 625 + 361 + 576 + 400 = 2446$$

$$s^2 = (2446 - 5 \times 22^2) / 4 = (2446 - 2420) / 4 = 26 / 4 = 6.5 \text{ G}^2$$



ATTENTION : NE PAS ARRONDIR $\bar{x}$ TROP TÔT !

Exemple 1 (suite) : les serpents dans R

Pour les 147 serpents :

$$\bar{x} = \frac{33.90 + 34.87 + \dots + 35.56}{147} = 34.882 \text{ g},$$
$$s = \sqrt{\frac{(33.90 - 34.882)^2 + \dots + (35.56 - 34.882)^2}{146}} = 0.956 \text{ g}.$$


(146 = n - 1)

Heureusement, R fait le calcul pour nous :

```
> serpents <- read.csv("serpents.csv")
> poids <- serpents$poids
> mean(poids)
[1] 34.88177
> sd(poids)
[1] 0.9560275
```

mean() → $\bar{x}$
sd() → s (DIVISE PAR $n - 1$)

Interpréter l'écart-type



Trait plein : $\bar{x} = 34.882$ g.

Tirets : $\bar{x} \pm s = [33.93; 35.84]$
104 serpents sur 147, soit **70.7 %**.

Pointillés : $\bar{x} \pm 2s = [32.97; 36.79]$
141 serpents sur 147, soit **95.9 %**.

70.7 % $\approx$ 68 %

95.9 % $\approx$ 95 %

$\Rightarrow$ BIEN « EN CLOCHE »




Règle empirique : pour une distribution **en cloche**, environ 68 % des observations sont à moins d'un écart-type de la moyenne et environ 95 % à moins de deux écarts-types (loi normale, chapitre 2).

Caractéristiques de la moyenne

- C'est le **point d'équilibre** de l'histogramme.
- Toutes les observations interviennent dans son calcul.
- Elle est **sensible aux valeurs extrêmes** : une seule valeur très grande (ou une erreur de saisie !) peut la déplacer beaucoup.

Autre mesure de dispersion : l'écart absolu moyen

$$d = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|$$



Plus simple à interpréter, mais peu utilisé : l'écart-type a de bien meilleures propriétés mathématiques (chapitres 2 et 3). Pour les serpents, $d = 0.779$ g, proche de $s = 0.956$ g.

QUIZ!

La pression artérielle systolique moyenne de 30 patients vaut $\bar{x} = 112$ mmHg. On retire la plus grande et la plus petite observations.

Vrai ou faux? La moyenne des 28 observations restantes vaut toujours 112 mmHg.

FAUX (EN GÉNÉRAL) !

SOMME DES 30 VALEURS = $30 \times 112 = 3360$
NOUVELLE MOYENNE = $(3360 - \text{MIN} - \text{MAX}) / 28$
= 112 SEULEMENT SI $\text{MIN} + \text{MAX} = 2 \times 112 = 224$

EX. : $\text{MIN} = 90, \text{MAX} = 150 \Rightarrow (3360 - 240) / 28 = 111.4 \neq 112$

Le coefficient de variation

Coefficient de variation (variable à valeurs positives)

$CV = s/\bar{x}$: mesure de dispersion **relative**, sans unité, souvent exprimée en %.

Exemple 4 : poids de rats et de lapins de laboratoire.

Population	n	$\bar{x}$ (g)	s (g)
Rats	75	110	11
Lapins	84	660	22

*S : RATS < LAPINS
CV : RATS > LAPINS
⇒ CV COMPARE DES
ÉCHELLES DIFFÉRENTES*

Les poids des lapins varient-ils plus que ceux des rats ?

$CV_{\text{rats}} = 11/110 = 10\%$ et $CV_{\text{lapins}} = 22/660 = 3.3\%$: l'écart-type est plus petit chez les rats, mais la variation **relative** est plus petite chez les lapins.

Moyenne et écart-type à partir de données groupées

Sans les données brutes, on fait comme si les f_j observations de la classe $(c_{j-1}, c_j]$ étaient toutes égales au **milieu** de la classe, $m_j = (c_{j-1} + c_j)/2$:

$$\bar{x} \approx \bar{x}^* = \frac{1}{n} \sum_{j=1}^{\ell} f_j m_j, \quad s \approx s^* = \sqrt{\frac{1}{n-1} \sum_{j=1}^{\ell} f_j (m_j - \bar{x}^*)^2}.$$

Exemple 2 (suite) : les milieux sont 15, 25, 35, 50 et 80 μm .

$$\bar{x}^* = \frac{25 \times 15 + 45 \times 25 + 35 \times 35 + 30 \times 50 + 20 \times 80}{155} = \frac{5825}{155} = 37.58 \mu\text{m},$$
$$s^* = \sqrt{\frac{25 \times (15 - 37.58)^2 + \dots + 20 \times (80 - 37.58)^2}{154}} = 19.86 \mu\text{m}.$$

*$\approx$: APPROX.
(DONNÉES BRUTES
INCONNUES)*

$$5825 = 375 + 1125 + 1225 + 1500 + 1600$$

$$\sum F_j (M_j - \bar{x}^*)^2 = 60\,718 \Rightarrow s^* = \sqrt{60\,718/154} = 19.86$$

QUIZ!

La balance du chercheur était mal tarée : chaque serpent a été pesé **2 g de trop**.

- Que deviennent la moyenne $\bar{x} = 34.882$ g et l'écart-type $s = 0.956$ g une fois les poids corrigés?

$$\bar{x} = 34.882 - 2 = 32.882 \text{ G} \quad (\text{DÉCALÉE DE 2 G})$$

$$s = 0.956 \text{ G} : \text{INCHANGÉ (LES ÉCARTS } x_i - \bar{x} \text{ NE CHANGENT PAS)}$$

- On exprime ensuite les poids corrigés en **milligrammes**. Que deviennent $\bar{x}$, s et le coefficient de variation?

$$\times 1000 : \bar{x} = 32\,882 \text{ MG} \quad s = 956 \text{ MG}$$

$$CV = 956 / 32\,882 = 0.956 / 32.882 = 2.9 \% : \text{INCHANGÉ}$$

MAIS LA CORRECTION DE 2 G A CHANGÉ LE CV :
 $0.956 / 34.882 = 2.74 \% \rightarrow 0.956 / 32.882 = 2.91 \%$


RÈGLE : SI $Y_i = AX_i + B$ ALORS

$$\bar{Y} = A\bar{X} + B \quad \text{ET} \quad S_Y = |A|S_X$$

CORRECTION : $A = 1, B = -2 \Rightarrow \bar{X}$ BAISSE DE 2, S INCHANGÉ

$G \rightarrow MG : A = 1000, B = 0 \Rightarrow \bar{X}$ ET $S \times 1000$, CV INCHANGÉ

LE CV CHANGE QUAND ON AJOUTE UNE CONSTANTE !



1.5 Les quantiles

Statistiques d'ordre

Exemple 5 : longueurs (en cm) de 7 truites mouchetées capturées dans un ruisseau :

22.3 17.9 20.4 24.6 19.5 26.2 18.7 → **ON TRIE !**

Statistiques d'ordre

On note $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$ les observations placées en **ordre croissant**. $x_{(1)}$ est le minimum et $x_{(n)}$ le maximum.

$x_{(1)}$	$x_{(2)}$	$x_{(3)}$	$x_{(4)}$	$x_{(5)}$	$x_{(6)}$	$x_{(7)}$	(i) = RANG (POSITION)
17.9	18.7	19.5	20.4	22.3	24.6	26.2	
MIN						MAX	

Les quantiles

Grosso modo, le **quantile d'ordre γ** ($0 \leq \gamma \leq 1$) est la valeur q_γ telle que $100\gamma\%$ des observations lui sont inférieures (et $100(1 - \gamma)\%$ lui sont supérieures).

Quantile échantillonnal d'ordre γ

$$q_\gamma = x_{(1+(n-1)\gamma)} \leftarrow \text{POSITION (RANG)}$$

Si $1 + (n - 1)\gamma$ n'est pas entier, on **interpole** entre les deux statistiques d'ordre voisines. Par exemple, $x_{(2.8)} = x_{(2)} + 0.8 \times (x_{(3)} - x_{(2)})$.

Il existe plusieurs définitions des quantiles échantillonnaux (très proches quand n est grand). Celle-ci est la définition par défaut de la fonction `quantile()` de R.

$$\gamma = 0 : x_{(1)} = \text{MIN} \quad \gamma = 0.5 : \text{MÉDIANE} \quad \gamma = 1 : x_{(n)} = \text{MAX}$$

Exemple 5 (suite) : quantile d'ordre 0.3

Rappel : 17.9 18.7 19.5 20.4 22.3 24.6 26.2 ($n = 7$)

Position : $1 + (n - 1)\gamma = 1 + (7 - 1) \times 0.3 = 2.8$, donc $x_{(2.8)}$ est à 80 % du chemin entre $x_{(2)}$ et $x_{(3)}$:

$$q_{0.3} = x_{(2)} + 0.8 \times (x_{(3)} - x_{(2)}) = 18.7 + 0.8 \times (19.5 - 18.7) = 19.34 \text{ cm.}$$



Serpents ($n = 147$) : $1 + 146 \times 0.4 = 59.4$, donc

ENTRE LE 59E ET LE 60E SERPENT

$$q_{0.4} = x_{(59)} + 0.4 \times (x_{(60)} - x_{(59)}) = 34.56 + 0.4 \times (34.59 - 34.56) = 34.572 \text{ g.}$$

Environ 40 % des serpents pèsent moins de 34.572 g. **R : quantile(poids, 0.4)**


Quartiles et centiles

Quartiles

- Premier quartile : $Q_1 = q_{0.25}$
- Deuxième quartile, ou **médiane** : $Q_2 = m = q_{0.50}$
- Troisième quartile : $Q_3 = q_{0.75}$

Les trois quartiles séparent l'échantillon en quatre parties de même effectif.

Le quantile $q_{k/100}$ est aussi appelé k^{e} **centile** (ou percentile). Ainsi, Q_1 est le 25^e centile, m le 50^e et Q_3 le 75^e.



La médiane

Avec la formule $q_{0.5} = x_{(1+(n-1)/2)}$, on obtient :

Médiane

$$m = \begin{cases} x_{(\frac{n+1}{2})} & \text{si } n \text{ est impair (valeur du milieu),} \\ \frac{x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}}{2} & \text{si } n \text{ est pair (moyenne des deux valeurs du milieu).} \end{cases}$$

Exemple 5 (suite) : $n = 7$, donc $m = x_{(4)} = 20.4 \text{ cm}$. $\frac{n+1}{2} = \frac{8}{2} = 4$


Exercice : calculez Q_1 et Q_3 pour les 7 truites.

$$Q_1 = x_{(1+6 \times 0.25)} = x_{(2.5)} = 18.7 + 0.5 \times (19.5 - 18.7) = 19.1 \text{ CM}$$

$$Q_3 = x_{(1+6 \times 0.75)} = x_{(5.5)} = 22.3 + 0.5 \times (24.6 - 22.3) = 23.45 \text{ CM}$$

Moyenne ou médiane ?

La médiane est une autre mesure de **tendance centrale**. Elle ne fait intervenir que la ou les observations du milieu : elle est **peu sensible aux valeurs extrêmes** (on dit qu'elle est *robuste*).



Remplacer 7 par 14 déplace la moyenne, mais pas la médiane.

QUIZ!

La pression artérielle systolique **médiane** de 30 patients vaut $m = 114$ mmHg. On retire la plus grande et la plus petite observations.

Vrai ou faux? La médiane des 28 observations restantes vaut toujours 114 mmHg.

VRAI !

$$N = 30 \text{ (PAIR)} : M = (x_{(15)} + x_{(16)})/2 = 114$$

ON RETIRE $x_{(1)}$ ET $x_{(30)}$: IL RESTE 28 VALEURS

LES ANCIENS $x_{(15)}$ ET $x_{(16)}$ SONT MAINTENANT LES 14^e ET 15^e

⇒ MÊMES VALEURS DU MILIEU : MÉDIANE = 114




QUIZ!

Voici la durée de séjour à l'hôpital de 200 patients.

- La moyenne est-elle plus grande, plus petite ou à peu près égale à la médiane? Pourquoi?

PLUS GRANDE : $\bar{x} > M$



Séjour à l'hôpital (jours)


- Même question pour une distribution asymétrique à gauche, puis pour une distribution symétrique.

**LA LONGUE QUEUE À DROITE
TIRE $\bar{x}$ VERS LE HAUT**

ASYM. À GAUCHE : $\bar{x} < M$ (GESTATION : 39.1 < 39.5 SEM.)


SYMÉTRIQUE : $\bar{x} \approx M$ (PRESSION : 120.8 $\approx$ 121 MMHG)

MOYENNE OU MÉDIANE : ÇA DÉPEND DE LA FORME



SYMÉTRIQUE


$$\bar{x} \approx M$$



QUEUE À DROITE

$$M \quad \bar{x}$$

$$\bar{x} > M$$



QUEUE À GAUCHE

$$\bar{x} \quad M$$

$$\bar{x} < M$$

LA MOYENNE EST « TIRÉE » VERS LA QUEUE ; LA MÉDIANE RÉSISTE.

Résumé à cinq nombres et mesures de dispersion

Avec $\gamma = 0$ et $\gamma = 1$: $q_0 = x_{(1)} = \min$ et $q_1 = x_{(n)} = \max$.

Résumé à cinq nombres

$$(x_{(1)}, Q_1, Q_2, Q_3, x_{(n)}) = (q_0, q_{0.25}, q_{0.50}, q_{0.75}, q_1)$$

- **Étendue** : $x_{(n)} - x_{(1)}$ (ne dépend que des deux valeurs les plus extrêmes);
- **Écart interquartile** : $ElQ = Q_3 - Q_1$ (étendue de la moitié centrale des données).

Serpents : (32.62, 34.19, 34.86, 35.535, 37.61), donc étendue = 4.99 g et $ElQ = 35.535 - 34.19 = 1.345$ g.

ÉTENDUE = 37.61 - 32.62 = 4.99 G : DÉPEND DES 2 EXTRÊMES (PAS ROBUSTE)
ElQ : MOITIÉ CENTRALE DES DONNÉES ⇒ ROBUSTE

Exemple 1 (suite) : les quantiles dans R

```
> quantile(poids, 0.4)
40%
34.572
> quantile(poids, c(0, 0.25, 0.5, 0.75, 1))
0%      25%      50%      75%      100%
32.620 34.190 34.860 35.535 37.610
> summary(poids)
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
 32.62  34.19   34.86   34.88   35.53   37.61
> IQR(poids)
[1] 1.345
```

MÊME Q_3 :
summary() ARRONDIT

La moyenne (34.88 g) et la médiane (34.86 g) sont presque égales : la distribution est à peu près **symétrique**.

summary() arrondit à 4 chiffres significatifs (35.535 devient 35.53).

Les rangs centiles

Ne pas confondre **centile** et **rang centile** ! Les 99 centiles $q_{0.01}, \dots, q_{0.99}$ découpent l'axe en 100 segments, numérotés de 1 à 100 à partir de la gauche.

Rang centile

Numéro du segment où se trouve l'observation : un rang centile de k signifie que l'observation est entre le $(k - 1)^e$ et le k^e centile.

Exemple 1 (suite) : le premier serpent pesait 33.90 g. Or $q_{0.13} = 33.8994$ et $q_{0.14} = 33.9232$. Le rang centile de ce serpent est donc **14** : environ 13 % des serpents sont plus légers que lui.



Les observations aberrantes

Une observation **aberrante** est très éloignée du centre de la distribution. Critère usuel (règle de 1.5 EIQ) :

Observation aberrante

$$x_i < Q_1 - 1.5 \text{ EIQ} \quad \text{ou} \quad x_i > Q_3 + 1.5 \text{ EIQ.}$$

Serpents : $Q_1 - 1.5 \text{ EIQ} = 34.19 - 1.5 \times 1.345 = 32.1725$ et
 $Q_3 + 1.5 \text{ EIQ} = 35.535 + 1.5 \times 1.345 = 37.5525$. Le serpent le plus lourd (37.61 g) est donc une observation aberrante.


Attention! « Aberrante » ne veut pas dire « à supprimer ». On vérifie d'abord s'il s'agit d'une erreur (de mesure, de saisie); sinon, on la garde : elle fait partie de la variabilité naturelle.

MIN = 32.62 > 32.1725 : PAS ABERRANT MAX = 37.61 > 37.5525 : ABERRANT !

1.6 Le diagramme en boîte

Le diagramme en boîte


Le **diagramme en boîte** (*boxplot*) est, à quelques détails près, une représentation graphique du résumé à cinq nombres.



- La boîte va de Q_1 à Q_3 : elle contient la moitié centrale des données (longueur = IQR). Le trait indique la médiane.
- Les bras (« moustaches ») s'arrêtent aux observations non aberrantes les plus extrêmes ; les observations aberrantes sont des points.

Procédure de construction d'un diagramme en boîte

1. On trace un axe gradué (vertical ou horizontal).
2. On dessine une boîte allant de Q_1 à Q_3 .
3. On trace un trait à travers la boîte vis-à-vis de la médiane Q_2 .
4. On **calcule** (sans les tracer) les bornes $b_{\text{inf}} = Q_1 - 1.5 \text{ ElQ}$ et $b_{\text{sup}} = Q_3 + 1.5 \text{ ElQ}$. ← « **CLÔTURES** »
5. **Bras inférieur** : de Q_1 jusqu'à la plus petite observation $\geq b_{\text{inf}}$.
6. **Bras supérieur** : de Q_3 jusqu'à la plus grande observation $\leq b_{\text{sup}}$.
7. Chaque observation aberrante (hors de $[b_{\text{inf}}, b_{\text{sup}}]$) est indiquée par un point ou un astérisque.



Exemple 6 : tiques sur des souris à pattes blanches

On a compté les tiques sur 11 souris à pattes blanches capturées en forêt (données déjà ordonnées) :




Construisons le diagramme en boîte.

- $Q_1 = x_{(1+10 \times 0.25)} = x_{(3.5)} = 5 + 0.5 \times (6 - 5) = 5.5$, $Q_2 = x_{(6)} = 8$,
 $Q_3 = x_{(8.5)} = 11 + 0.5 \times (12 - 11) = 11.5$
- $ElQ = 11.5 - 5.5 = 6$, $b_{inf} = 5.5 - 1.5 \times 6 = -3.5$,
 $b_{sup} = 11.5 + 1.5 \times 6 = 20.5$


$PLUS\ PETITE \geq -3.5 : 2$
 $PLUS\ GRANDE \leq 20.5 : 14$
- Bras inférieur jusqu'à 2; bras supérieur jusqu'à 14; 31 est une observation aberrante. $31 > 20.5 \Rightarrow ABERRANTE$

CONSTRUCTION À LA MAIN (EXEMPLE 6)

1. $Q_1 = 5.5$, $Q_2 = 8$, $Q_3 = 11.5 \rightarrow$ LA BOÎTE
2. $EIQ = 6$; CLÔTURES : $5.5 - 9 = -3.5$ ET $11.5 + 9 = 20.5$
3. BRAS : JUSQU'À 2 ET JUSQU'À 14 (DANS LES CLÔTURES)
4. $31 > 20.5$: ABERRANTE $\rightarrow$ UN POINT



Exemple 6 (suite) : le diagramme et la moyenne



```
> tiques <- c(2, 3, 5, 6, 7, 8, 9, 11, 12, 14, 31)
> summary(tiques)
  Min. 1st Qu.  Median    Mean 3rd Qu.   Max.
 2.000  5.500   8.000   9.818 11.500  31.000
> boxplot(tiques, horizontal = TRUE)
```

SANS LE 31 :
 $\bar{x} = 77 / 10 = 7.7$
 $m = (7 + 8) / 2 = 7.5$

La souris très infestée tire la moyenne vers le haut : $\bar{x} = 9.82 > m = 8$. Sans elle, $\bar{x} = 7.7$ et $m = 7.5$: la moyenne baisse de plus de 2 tiques, la médiane de 0.5 seulement.

Que nous apprend un diagramme en boîte ?


En un coup d'œil, on voit :

- le **centre** de la distribution (la médiane);
- la **dispersion** (longueur de la boîte = EIQ, longueur des bras);
- la **symétrie** : la médiane est-elle au milieu de la boîte ? Les bras sont-ils de même longueur ?
- la présence d'observations **aberrantes**.

L'histogramme donne en général une meilleure idée de la forme de la distribution... mais le diagramme en boîte est **idéal pour comparer plusieurs échantillons** côte à côte.



Diagrammes en boîte juxtaposés



Poids à la naissance (g) dans 5 populations de serpents
(données fictives)

On veut comparer le poids à la naissance dans 5 populations de serpents. Que remarquez-vous ?


- Poids les plus élevés : populations **B** et **E**.
- Poids les plus faibles : population **D**.
- Plus grande variabilité : populations **B** et **D**.
- Population A : une observation aberrante.

Comparer les moyennes de plusieurs groupes : c'est l'objet de l'**ANOVA** (chapitre 5).


QUIZ!

Associez chaque histogramme (A, B, C) à son diagramme en boîte (1, 2, 3).


A




1 = C




B




2 = B



C



3 = A



Pour chacune, la moyenne est-elle plus grande ou plus petite que la médiane?

A : $\bar{x} \approx M$ (SYMÉTRIQUE) B : $\bar{x} > M$ (QUEUE À DROITE)

C : $\bar{x} < M$ (QUEUE À GAUCHE)

Petit détail technique : la boîte de R

Lorsque n est **pair**, la fonction `boxplot()` de R ne place pas les côtés de la boîte exactement en Q_1 et Q_3 , mais à mi-chemin entre deux observations voisines (« charnières » de Tukey). Exemple avec 12 données :

```
> y <- c(1, 2, 3, 7, 7, 7, 8, 9, 10, 20, 21, 24)
> quantile(y, c(0.25, 0.75))    # Q1 et Q3 (définition du cours)
  25%    75%
 6.0   12.5
> boxplot.stats(y)$stats        # bras, charnières et médiane de boxplot()
[1]  1.0  5.0  7.5 15.0 24.0
```

Boîte de 6 à 12.5 selon la méthode du cours, de 5 à 15 dans R. Quand n est impair (serpents, tiques), les deux méthodes coïncident. En pratique, ces différences sont sans importance.

CHARNIÈRE = MÉDIANE DE CHAQUE MOITIÉ (VOIR PAGE SUIVANTE)

Y: 1 2 3 7 7 7 / 8 9 10 20 21 24 (N = 12)

CHARNIÈRES (R) :

INF. = MÉDIANE DE 1, 2, 3, 7, 7, 7 = $(3 + 7) / 2 = 5$

SUP. = MÉDIANE DE 8, 9, 10, 20, 21, 24 = $(10 + 20) / 2 = 15$

QUARTILES (COURS) :

$$Q_1 = X_{(1+11) \times 0.25} = X_{(3.75)} = 3 + 0.75 \times (7 - 3) = 6$$

$$Q_3 = X_{(1+11) \times 0.75} = X_{(9.25)} = 10 + 0.25 \times (20 - 10) = 12.5$$

MÉDIANE = $(7 + 8) / 2 = 7.5$ DANS LES DEUX CAS


Complément : le diagramme quantile-quantile normal

Plusieurs méthodes des chapitres 3 à 6 supposent que les données proviennent d'une **loi normale** (distribution « en cloche », chapitre 2). Comment le vérifier ?

- **Principe** : on compare les quantiles de l'échantillon à ceux auxquels on s'attendrait sous une loi normale.
- **Technique** (*grosso modo*) : on associe à chaque statistique d'ordre $x_{(i)}$ le quantile de la loi normale d'ordre $\approx i/(n+1)$, puis on trace les n points.
- **Lecture** : si le modèle normal est bon, les points sont à peu près **alignés** sur une droite.

Dans R : `qqnorm(poids)`, puis `qqline(poids)` pour ajouter la droite de référence.

Exemple 1 (suite) : les serpents




Les 147 points sont **très bien alignés** sur la droite (rouge).

⇒ La loi normale est un modèle raisonnable pour le poids à la naissance de ces serpents, comme le suggérait déjà l'histogramme « en cloche ».

Le serpent aberrant (37.61 g) est le dernier point en haut à droite : à lui seul, il ne remet pas en cause le modèle.

Comment lire un diagramme quantile-quantile



- **Échantillon normal** : points alignés (dans la bande pointillée).
- **Asymétrie à droite** : les points s'écartent vers le haut à droite (courbe convexe).
- **Asymétrie à gauche** : les points s'écartent vers le bas à gauche (courbe concave).
- **Valeurs extrêmes** (queues lourdes) : les deux extrémités s'écartent de la droite (forme de S).

1.7 Diagrammes en pointes de tarte et en bâtons

Exemple 7 : une variable qualitative

Pour une variable **qualitative**, on résume les données par un tableau de fréquences. On a demandé à 275 écoliers leur fruit préféré parmi les six fruits les plus consommés au Québec.


Fruit	Fréquence	Fréq. relative	Angle (degrés)
Banane	69	0.251	$\frac{69}{275} \times 360 = 90.33$
Nectarine	35	0.127	45.82
Orange	14	0.051	18.33
Pêche	39	0.142	51.05
Poire	41	0.149	53.67
Pomme	77	0.280	100.80
Total	275	1	360

ANGLE =
FRÉQ. REL.
 $\times 360^\circ$

POMME :
 $77 / 275$
 $= 0.280$
 $\times 360$
 $= 100.8^\circ$


Exemple 7 (suite) : pointes de tarte et bâtons

Diagramme en pointes de tarte



Angle (et surface) de chaque pointe $\propto$ fréquence.

Diagramme en bâtons



L'œil compare mieux des **longueurs** que des **angles** : le diagramme en bâtons est généralement plus lisible (Poire ou Pêche?).

POIRE : 41 > PÊCHE : 39

Diagramme en bâtons ou histogramme ?

- **Histogramme** : variable **quantitative** continue. L'axe horizontal est gradué ; les rectangles se touchent ; c'est la **surface** qui compte.
- **Diagramme en bâtons** : variable **qualitative** (ou quantitative discrète avec peu de valeurs). Les bâtons sont séparés ; l'ordre des catégories est arbitraire pour une variable nominale.


Dans R, pour une variable qualitative `f` : `table(f)` (tableau de fréquences), `barplot(table(f))` (bâtons), `pie(table(f))` (pointes de tarte).

Les tableaux de fréquences et leur analyse (test du khi-deux) seront approfondis au chapitre 7.

1.8 Les données bivariées

Exemple 8 : deux variables à la fois

On mesure deux variables quantitatives X et Y sur chacun des n individus : les données sont n couples $(x_1, y_1), \dots, (x_n, y_n)$.



Poids et étendue des ailes de 38 des 50 hirondelles de l'exemple 2 du chapitre 6.

Ce **diagramme de dispersion** (*scatterplot*) montre une association **positive** : les hirondelles plus lourdes ont tendance à avoir des ailes plus étendues.

Dans R : `plot(x, y)`.

Le coefficient de corrélation

Coefficient de corrélation échantillonnal

$$r = \frac{1}{n-1} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s_x} \right) \left(\frac{y_i - \bar{y}}{s_y} \right)$$

PRODUIT DES
ÉCARTS
STANDARDISÉS

- $-1 \leq r \leq 1$: il mesure le degré d'association **linéaire** entre X et Y.
- $r > 0$: association positive; $r < 0$: association négative; $r \approx 0$: pas d'association linéaire.


Exemple 8 (suite) : $\bar{x} = 47.53$ g, $s_x = 4.73$ g, $\bar{y} = 11.17$ cm, $s_y = 1.74$ cm, et $\text{cor}(x, y)$ donne $r = 0.890$: forte association linéaire positive.

0.890 : PROCHE DE 1 $\Rightarrow$ POINTS PRÈS D'UNE DROITE CROISSANTE


Quelques valeurs de r




Corrélation = 0.3




Corrélation = 0.6




Corrélation = 0.9




Corrélation = -0.3



Corrélation = -0.6



Corrélation = -0.9



Attention! Une forte corrélation ne prouve pas une relation de **cause à effet**. Et r ne mesure que l'association **linéaire** : une relation courbe peut donner $r \approx 0$. Toujours regarder le graphique! Nous y reviendrons au chapitre 6.

QUIZ!

Exemple 8 (hirondelles), $r = 0.890$.

- On exprime maintenant le poids en kilogrammes plutôt qu'en grammes. La valeur de r change-t-elle?

NON ! r NE DÉPEND PAS DES UNITÉS :
ÉCARTS STANDARDISÉS $(x_i - \bar{x})/s_x$ SANS UNITÉ

- On calcule plutôt la corrélation entre l'étendue des ailes et le poids (on inverse les rôles de X et Y). Que vaut r ?

$r = 0.890$ AUSSI :
LA FORMULE EST SYMÉTRIQUE EN X ET Y

Que choisir ?

Type de données	Résumés numériques	Graphiques
Une variable quantitative	$\bar{x}$, m , quantiles; s , CV, EIQ	histogramme, boîte, quantile-quantile
Idem, plusieurs groupes	les mêmes, par groupe	boîtes juxtaposées
Une variable qualitative	fréquences (relatives)	bâtons, pointes de tarte
Deux variables quantitatives	coefficient de corrélation r	diagramme de dispersion

À retenir : la moyenne et l'écart-type sont sensibles aux valeurs extrêmes; la médiane et l'EIQ sont robustes. Toujours **regarder les données** (graphique) avant de calculer!

Prochain chapitre : les probabilités, pour passer de la description à l'inférence.

Aide-mémoire R

```
donnees <- read.csv("serpents.csv") # importer un fichier de données
x <- donnees$poids                  # extraire une variable
mean(x); median(x)                 # moyenne, médiane
sd(x); var(x); sd(x) / mean(x)     # écart-type, variance, CV
quantile(x, 0.4)                   # quantile d'ordre 0.4
summary(x); IQR(x)                 # résumé à cinq nombres + moyenne, EIQ
hist(x, breaks = seq(32.5, 38, by = 0.5)) # histogramme (classes choisies)
boxplot(x)                         # diagramme en boîte
boxplot(y ~ groupe, data = d)      # boîtes juxtaposées (une par groupe)
qqnorm(x); qqline(x)               # diagramme quantile-quantile normal
table(f); barplot(table(f))        # variable qualitative f
plot(x, y); cor(x, y)              # deux variables quantitatives
```

Réponses aux exemples

Quiz (types de variables) : a) qualitative nominale; b) quantitative continue; c) qualitative ordinale; d) quantitative discrète; e) quantitative continue; f) qualitative nominale; g) qualitative ordinale.

Quiz (exemple 2) : $(45 + 35)/155 = 0.516$, soit 51.6 %. C'est la surface des rectangles au-dessus de $(20, 40]$: $10 \times 0.0290 + 10 \times 0.0226 = 0.516$. La surface totale vaut 1; la somme des hauteurs n'a pas d'interprétation simple.

Exemple 3 : $\bar{x} = 22$ g, $s^2 = 6.5$ g², $s = 2.55$ g.

Quiz (moyenne, 30 patients) : Faux en général. La moyenne reste 112 seulement si les deux valeurs retirées ont une somme de $2 \times 112 = 224$.

Quiz (balance mal tarée) : $\bar{x}$ diminue de 2 g (32.882 g); s ne change pas (0.956 g). En mg : $\bar{x} = 32\,882$ mg et $s = 956$ mg (multipliés par 1000); le CV ne change pas en passant aux mg ($0.956/32.882 = 2.9\%$ dans les deux unités), mais il avait changé lors de la correction de 2 g ($2.74\% \rightarrow 2.91\%$).

Exemple 5 : $q_{0.3} = 19.34$ cm; $m = 20.4$ cm; $Q_1 = x_{(2.5)} = 18.7 + 0.5 \times 0.8 = 19.1$ cm; $Q_3 = x_{(5.5)} = 22.3 + 0.5 \times 2.3 = 23.45$ cm.

Réponses aux exemples (suite)

Quiz (médiane, 30 patients) : Vrai. Avec $n = 30$, la médiane est la moyenne de $x_{(15)}$ et $x_{(16)}$; après le retrait, ces deux valeurs sont toujours au milieu (ce sont les 14^e et 15^e des 28 valeurs restantes).

Quiz (séjour à l'hôpital) : asymétrie à droite, les grandes valeurs tirent la moyenne vers le haut : $\bar{x} = 4.61$ jours $> m = 3.8$ jours. Asymétrie à gauche : $\bar{x} < m$ (gestation : 39.1 contre 39.5 semaines). Symétrique : $\bar{x} \approx m$ (pression : 120.8 contre 121 mmHg).

Exemple 6 : résumé à cinq nombres (2, 5.5, 8, 11.5, 31); $ElQ = 6$; bornes -3.5 et 20.5 ; 31 est aberrante; $\bar{x} = 9.82$.

Quiz (histogrammes et boîtes) : A-3, B-2, C-1. A : $\bar{x} \approx m$; B : $\bar{x} > m$; C : $\bar{x} < m$.

Quiz (exemple 8) : r ne change pas quand on change d'unités (les données sont standardisées dans la formule); il est aussi symétrique en X et Y : $r = 0.890$ dans les deux cas.

Références

Ce document est rédigé avec Beamer ainsi qu'une classe .cls fournie par Jérôme Soucy.

Les diapositives sont adaptées des diapositives créées par Emmanuelle Reny-Nolin pour le cours STT-1920 ainsi que de celles des cours STT-1000 et STT-1900.

Référence : C. Bélisle, *STT-1920 Méthodes statistiques*, notes de cours, Université Laval, 2020, chapitre 1.