

Chapitre 6b – Régression linéaire simple (suite)

STT-1920 Méthodes statistiques

Département de mathématiques et de statistique



UNIVERSITÉ
LAVAL

Plan

Prédictions

Qualité de l'ajustement

Vérification des postulats

Prédictions

Intervalle de confiance pour la moyenne de Y en x^* : exemple

On voudrait construire un intervalle de confiance à 95 % pour la **production moyenne attendue de tous les plants** ayant reçu 6,5 heures d'ensoleillement par jour.

Rappel des calculs du chapitre 6a : $\bar{x} = 5,5$, $\bar{y} = 3,744$, $S_{XX} = 175$, $S_{XY} = 75,470$, d'où

$$b_1 = \frac{75,470}{175} = 0,4313, \quad b_0 = 3,744 - 0,4313 \times 5,5 = 1,3724, \quad \hat{\sigma}^2 = \text{MSE} = 0,3228.$$


La droite de régression estimée est donc $\hat{y} = 1,3724 + 0,4313 x$.

$x^* = 6,5 \text{ h}$: ON ESTIME

$$E(Y) = \beta_0 + \beta_1 \times 6,5$$

= UNE CONSTANTE $\Rightarrow$ IC

(LA MOYENNE DE TOUS LES PLANTS À 6,5 H)



IC pour la moyenne de Y en x^*

La valeur moyenne de Y lorsque $X = x^*$ est le point sur la vraie droite en x^* : $\beta_0 + \beta_1 x^*$, estimé par $b_0 + b_1 x^*$. On peut montrer que

$$b_0 + b_1 x^* \sim N \left(\overset{\text{MOYENNE}}{\beta_0 + \beta_1 x^*}, \overset{\text{VARIANCE}}{\sigma^2 \left[\frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{XX}} \right]} \right).$$

Intervalle de confiance de niveau $1 - \alpha$ pour $\beta_0 + \beta_1 x^*$

On estime σ^2 par le MSE et on obtient

$$(b_0 + b_1 x^*) \pm t_{n-2; \alpha/2} \sqrt{\text{MSE} \left[\frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{XX}} \right]}. \quad \leftarrow \text{ERREUR-TYPE DE } b_0 + b_1 x^*$$

σ^2 INCONNUE $\rightarrow$ ON L'ESTIME PAR MSE $\rightarrow$ LOI T_{n-2}

Exemple : IC pour la production moyenne à 6,5 h

On a $\bar{x} = 5,5$ h et $s_x^2 = 2,966$ (donc $S_{XX} = 59 \times 2,966 = 175$).

$$x^* = 6,5 : \hat{y} = 1,3724 + 0,4313 \times 6,5 = 4,176 \text{ KG}$$

$$\begin{aligned} \text{ERREUR-TYPE : } \sqrt{MSE \left[\frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{XX}} \right]} &= \sqrt{0,3228 \left[\frac{1}{60} + \frac{(6,5 - 5,5)^2}{175} \right]} \\ &= \sqrt{0,3228 \times 0,02238} = \sqrt{0,00722} = 0,0850 \end{aligned}$$

$$\text{IC À 95 \% : } 4,176 \pm 2,0017 \times 0,0850 = 4,176 \pm 0,170$$

$$t_{58; 0,025} = 2,0017$$

$$\Rightarrow [4,01 ; 4,35] \text{ KG}$$

AVEC 95 % DE CONFIANCE, LA PRODUCTION MOYENNE DE TOUS LES PLANTS RECEVANT 6,5 H DE SOLEIL PAR JOUR EST ENTRE 4,01 ET 4,35 KG.

Précision optimale?

Question : pour quelle valeur de x^* obtient-on la meilleure précision ?


$$(b_0 + b_1 x^*) \pm t_{n-2; \alpha/2} \sqrt{\text{MSE} \left[\frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{XX}} \right]}$$

QUAND $x^* = \bar{x} = 5,5 \text{ h}$


LE TERME $(x^* - \bar{x})^2$ S'ANNULE :

ERREUR-TYPE MINIMALE = $\sqrt{\text{MSE}/n}$

**PLUS x^* EST LOIN DE $\bar{x}$,
MOINS L'ESTIMATION EST PRÉCISE.**



Bornes de confiance à 95 % pour la valeur moyenne de Y



Intervalle de prédiction pour une observation future

Le producteur veut vendre des semis de cette variété de tomates, et indiquer des productions attendues dans des conditions similaires (terreau, arrosage, engrais, etc.) pour diverses durées d'ensoleillement quotidien.

- Selon notre modèle, **le** plant recevant 6,5 heures d'ensoleillement produira combien de kilos de tomates? $\hat{y} = 1,3724 + 0,4313 \times 6,5 = 4,18 \text{ KG (MÊME VALEUR)}$
- Quelle est l'erreur-type associée à cette estimation? Sera-t-elle plus grande ou plus petite que celle de la moyenne attendue avec 6,5 h de soleil?

PLUS GRANDE ! UN PLANT VARIE AUTOUR DE LA MOYENNE :

$$V(y^* - \hat{y}) = \underbrace{\sigma^2}_{\text{PLANT}} + \underbrace{\sigma^2 \left[\frac{1}{N} + \frac{(x^* - \bar{x})^2}{S_{XX}} \right]}_{\text{DROITE}}$$

Intervalle de prédiction

Ici, on n'estime plus une constante (la moyenne de la population au point x^*), mais une **variable aléatoire** (une nouvelle observation). Sa variance sera donc plus grande que celle de la moyenne.

Intervalle de prédiction de niveau $1 - \alpha$ pour une valeur future de Y

En estimant σ^2 par le MSE :

$$(b_0 + b_1 x^*) \pm t_{n-2; \alpha/2} \sqrt{\text{MSE} \left[1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{XX}} \right]}.$$

LE « 1 + » : VARIANCE σ^2 D'UNE NOUVELLE OBSERVATION

⇒ L'IP EST TOUJOURS PLUS LARGE QUE L'IC

Exemple

Construire un intervalle de prédiction à 95 % pour la production de tomates du plant ayant reçu 6,5 heures d'ensoleillement.

$\hat{Y} = 4,176 \text{ KG}$ (MÊME VALEUR QU'AVANT)

$$\begin{aligned}\text{ERREUR-TYPE : } & \sqrt{0,3228 \left[1 + \frac{1}{60} + \frac{(6,5 - 5,5)^2}{175} \right]} \\ & = \sqrt{0,3228 \times 1,02238} = \sqrt{0,3300} = 0,5745\end{aligned}$$

$$\text{IP À 95 \% : } 4,176 \pm 2,0017 \times 0,5745 = 4,176 \pm 1,150$$

$$\Rightarrow [3,03 ; 5,33] \text{ KG}$$

AVEC 95 % DE CONFIANCE, UN PLANT QUI REÇOIT 6,5 H DE SOLEIL PAR JOUR PRODUIRA ENTRE 3,03 ET 5,33 KG.

IC : $\pm 0,17$ IP : $\pm 1,15$ $\Rightarrow$ ENVIRON 7 FOIS PLUS LARGE !

POURQUOI LE « 1 + » ?

NOUVELLE OBSERVATION : $Y^* = \beta_0 + \beta_1 X^* + \varepsilon^*$

PRÉDICTION : $\hat{Y}^* = b_0 + b_1 X^*$

$$Y^* - \hat{Y}^* = \underbrace{(\beta_0 + \beta_1 X^*) - (b_0 + b_1 X^*)}_{\text{ERREUR SUR LA DROITE}} + \underbrace{\varepsilon^*}_{\text{VARIATION DU PLANT}}$$

$$V(Y^* - \hat{Y}^*) = \sigma^2 \left[\frac{1}{N} + \frac{(X^* - \bar{X})^2}{S_{XX}} \right] + \sigma^2 \quad (\text{INDÉPENDANTS})$$

$$= \sigma^2 \left[1 + \frac{1}{N} + \frac{(X^* - \bar{X})^2}{S_{XX}} \right]$$


SI $N \rightarrow \infty$:

IC $\rightarrow 0$

MAIS IP $\rightarrow \pm 1,96 \sigma$

Bornes de prédiction à 95 % pour une valeur future de Y

LES 60 POINTS SONT TOUS DANS LES BORNES DE PRÉDICTION



Tirets : bornes de confiance pour la moyenne; pointillés : bornes de prédiction.

En R : `predict()`

```
> nouveau <- data.frame(hrs_soleil=6.5)
> predict(RegModel.1, newdata=nouveau, interval="confidence")
      fit      lwr      upr
1 4.17559 4.005455 4.345725 ← IC (MOYENNE)
> predict(RegModel.1, newdata=nouveau, interval="prediction")
      fit      lwr      upr
1 4.17559 3.025689 5.325492 ← IP (UN PLANT)
```

- Même estimation ponctuelle (`fit`) dans les deux cas : 4,18 kg.
- L'intervalle de prédiction est environ 7 fois plus large : la variabilité d'un plant individuel (σ^2) domine.

LARGEURS : IC : $4,346 - 4,005 = 0,34$ IP : $5,325 - 3,026 = 2,30$

$2,30 / 0,34 = 6,8$: ENVIRON 7 FOIS PLUS LARGE

IC ou intervalle de prédiction ?

	IC pour la moyenne	Intervalle de prédiction
Cible	$E(Y) = \beta_0 + \beta_1 x^*$ (une constante)	une nouvelle observation Y (aléatoire)
Question type	« En moyenne, les plants à 6,5 h... »	« Ce plant-ci, à 6,5 h... »
Sous la racine	$\frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{XX}}$	$1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{XX}}$
Si $n \rightarrow \infty$	largeur $\rightarrow 0$	largeur $\rightarrow 2 \times 1,96 \sigma$ ($\approx 2,2 \text{ KG IC}$)

- Les deux sont plus étroits en $x^* = \bar{x}$ et s'élargissent en s'éloignant de $\bar{x}$.
- **Extrapolation dangereuse** (chapitre 6a) : ne pas prédire hors du domaine observé (ici, de 3 à 8 h).

QUIZ!

IC pour la moyenne ou intervalle de prédiction ?

- Un agronome veut estimer la production moyenne de l'ensemble des plants de cette variété cultivés avec 7 h de soleil par jour.

IC POUR LA MOYENNE ($E(Y)$ À 7 H)

- Une jardinière vient d'acheter un plant qu'elle placera 7 h par jour au soleil ; elle veut savoir combien il produira.

INTERVALLE DE PRÉDICTION (UN SEUL PLANT)

- Vrai ou faux : avec un très grand nombre de plants ($n \rightarrow \infty$), la largeur de l'intervalle de prédiction tend vers 0.

FAUX ! L'IP TEND VERS $\hat{y} \pm 1,96 \sigma$ (LARGEUR $\approx 2 \times 1,96 \times 0,568 = 2,2$ KG) ; C'EST L'IC QUI TEND VERS 0.

- Vrai ou faux : à 7 h de soleil, l'IC pour la moyenne est plus étroit qu'à 6,5 h.

FAUX ! 7 H EST PLUS LOIN DE $\bar{x} = 5,5$ QUE 6,5 H $\Rightarrow$ IC PLUS LARGE ($\pm 0,195$ VS $\pm 0,170$)

Qualité de l'ajustement

Coefficient de détermination R^2

On sait que $SSR + SSE = SST$.



Coefficient de détermination

R^2 = proportion de la variabilité totale de Y expliquée par le modèle (par la variable X)

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$$

Propriétés :

- $0 \leq R^2 \leq 1$;
- $R^2 = 0$ si... $SSR = 0 : b_1 = 0$
- $R^2 = 1$ si... $SSE = 0 : \text{POINTS SUR LA DROITE}$



Exemple

	Sum Sq	Df	F value	Pr(>F)	
hrs_soleil	32.547	1	100.83	2.661e-14	***
Residuals	18.721	58			

Calculez et interprétez le R^2 .

$$R^2 = \frac{SSR}{SST} = \frac{32,547}{32,547 + 18,721} = \frac{32,547}{51,268} = 0,635$$

63,5 % DE LA VARIABILITÉ DE LA PRODUCTION EST EXPLIQUÉE
PAR LA RELATION LINÉAIRE AVEC L'ENSOLEILLEMENT.

LE RESTE (36,5 %) : AUTRES FACTEURS ET HASARD

(DANS summary() : Multiple R-squared = 0.6348)

Coefficient de corrélation r

Le coefficient de corrélation mesure le **degré d'association linéaire** entre X et Y.

Coefficient de corrélation

$$r = \frac{S_{XY}}{\sqrt{S_{XX}S_{YY}}} = (\text{signe de } b_1) \sqrt{R^2}$$

ESTIME $\rho = \frac{\text{COV}(X,Y)}{\sigma_X \sigma_Y}$ OÙ $\text{COV}(X,Y) = E[(X - E(X))(Y - E(Y))]$

TOMATES: $R = \frac{75,47}{\sqrt{175 \times 51,268}} = \frac{75,47}{94,72} = 0,797$


SANS UNITÉ ; $R^2 = R^2$

Propriétés de r

- $-1 \leq r \leq 1$;
- $r > 0$ si $b_1 > 0$: POINTS AUTOUR D'UNE DROITE DE PENTE POSITIVE
- $r < 0$ si $b_1 < 0$: POINTS AUTOUR D'UNE DROITE DE PENTE NÉGATIVE
- $r = 1$ ou -1 si tous les points sont alignés;
- $r = 0$ si la pente de la droite estimée est nulle; **MAIS $\neq$ AUCUNE RELATION !**
- r ne mesure pas la causalité de la relation.

r ET b_1 ONT TOUJOURS LE MÊME SIGNE.

QUE VAUT R ICI ?



$R = 0 !$

MAIS LA RELATION
EST PARFAITE
($y = x^2$) !

DROITE : $B_1 = 0$


R MESURE SEULEMENT
LE LIEN LINÉAIRE.

⇒ TOUJOURS REGARDER
LE GRAPHIQUE !


Quelques nuages de points et leur corrélation

$r > 0$


$r = 0.3$



$r = 0.6$




$r = 0.9$




PLUS $|r|$ EST
PROCHE DE 1,
PLUS LES
POINTS SONT
SERRÉS AUTOUR
DE LA DROITE


$r = -0.3$



$r = -0.6$



$r = -0.9$



$r < 0$

Exemple

Quel est le coefficient de corrélation entre la production de tomates et le temps d'ensoleillement ?

$$R = \text{SIGNE}(B_1) \times \sqrt{R^2}$$

$$= \text{SIGNE}(0,431) \times \sqrt{0,635}$$

$$= +0,797$$

LIEN LINÉAIRE
POSITIF ET
ASSEZ FORT

```
> cor(tomates[,c("hrs_soleil", "production")])  
           hrs_soleil production  
hrs_soleil  1.0000000  0.7967679  
production  0.7967679  1.0000000
```

QUIZ!

- Pour les hirondelles (chapitre 6a), on obtient $R^2 = 0,792$ et une pente positive. Que vaut r ? Interprétez R^2 .

$r = +\sqrt{0,792} = 0,89$ (PENTE POSITIVE)

79 % DE LA VARIABILITÉ DE L'ÉTENDUE DES AILES EST EXPLIQUÉE PAR LE POIDS.

- Vrai ou faux : $r = -0,9$ indique un lien linéaire plus faible que $r = 0,5$.

FAUX ! $1 - 0,9 = 0,1 < 0,5$: LIEN PLUS FORT (MAIS NÉGATIF)

- Vrai ou faux : si $r = 0$, il n'y a aucune relation entre X et Y.

FAUX ! r NE MESURE QUE LE LIEN LINÉAIRE (EX. : EN V, $r \approx 0$)


- Vrai ou faux : un R^2 élevé garantit que les postulats du modèle sont respectés.

FAUX ! IL FAUT EXAMINER LES RÉSIDUS
(EX. 3 PLUS LOIN : $R^2 = 0,875$ MAIS RELATION COURBE)

Pourquoi « régression » ?

- Le terme vient de Francis Galton, *Regression towards mediocrity in hereditary stature* (Journal of the Anthropological Institute, 1886).
- Galton a comparé la taille d'enfants à la taille moyenne de leurs parents : les enfants de parents très grands sont en moyenne grands, mais **moins** que leurs parents ; ceux de parents très petits sont petits, mais moins que leurs parents.
- Les tailles « régressent » vers la moyenne : la pente de la droite est inférieure à 1. C'est la **régression vers la moyenne**.
- Karl Pearson (1903) a observé le même phénomène sur plus de 1000 paires père-fils.

Régression vers la moyenne



Données simulées selon les caractéristiques des données père-fils de Pearson (1903) : corrélation d'environ 0,5.

Vérification des postulats

Les postulats

Tests et intervalles reposent sur les postulats suivants, **en ordre d'importance** :

- (P1) **Linéarité** : la moyenne de Y est une fonction linéaire de X; ← **LE PLUS IMPORTANT**
- (P2) **Homoscédasticité** : la variance autour de la droite est la même pour toutes les valeurs de X;
- (P3) **Indépendance** des observations;
- (P4) **Normalité** des observations autour de la droite. *(MOINS GRAVE SI N EST GRAND)*

Outils de vérification

- (P1) nuage (x_i, y_i) ; résidus en fonction des valeurs prédites $\hat{y}_i$
- (P2) résidus en fonction des valeurs prédites $\hat{y}_i$
- (P3) mode de collecte des données; résidus selon l'ordre de collecte
- (P4) histogramme, diagramme quantile-quantile, test de Shapiro-Wilk

Analyse des résidus

Rappel du modèle : $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$. $\varepsilon_i = y_i - (\beta_0 + \beta_1 x_i)$


Puisque $Y_i \sim N(\beta_0 + \beta_1 X_i, \sigma^2)$, il suit que $\varepsilon_i \sim N(0, \sigma^2)$.

Résidus

Les erreurs échantillonales ε_i sont estimées par les **résidus** du modèle :

$$\hat{\varepsilon}_i = y_i - \hat{y}_i = y_i - (b_0 + b_1 x_i).$$

Au lieu d'analyser directement les observations, nous analyserons les résidus.



RÉSIDU = OBSERVÉ - PRÉDIT

= ÉCART VERTICAL ENTRE LE POINT ET LA DROITE

$\varepsilon_i > 0$: AU-DESSUS ; $\varepsilon_i < 0$: EN DESSOUS

PROPRIÉTÉ : $\sum \varepsilon_i = 0$

Calcul des résidus

Dans notre exemple, $\hat{y} = 1,372 + 0,431 x$. Voici quelques calculs de résidus :

Donnée i	1	12	24	51
Heures de soleil x_i	3	4	5	8
Production observée y_i	2,92	2,92	3,21	4,08
Production prédite $b_0 + b_1 x_i$	2,67	3,10	3,53	4,82
Résidu $\hat{\epsilon}_i$	0,25	-0,18	-0,32	-0,74


$$\hat{y}_{51} = 1,372 + 0,431 \times 8 = 4,82 \quad \epsilon_{51} = 4,08 - 4,82 = -0,74$$

→ CE PLANT A PRODUIT 0,74 KG DE MOINS QUE PRÉVU (POINT SOUS LA DROITE)

(P1) Linéarité

Le nuage (x_i, y_i) doit être réparti symétriquement autour d'une droite, et le graphique des résidus e_i en fonction de $\hat{y}_i$, autour de 0, **sans tendance**.


Linéarité raisonnable



y_i selon x_i

e_i selon $\hat{y}_i$

Linéarité déraisonnable



y_i selon x_i

e_i selon $\hat{y}_i$

À droite : la tendance est courbe ; les résidus forment un « arc » (négatifs aux extrémités, positifs au centre).


BANDE HORIZONTALE AUTOUR DE 0 ✓

ARC $\Rightarrow$ RELATION COURBE ✗

(P2) Homoscédasticité


Dans le graphique des résidus e_i en fonction des valeurs prédites $\hat{y}_i$, la **dispersion verticale** doit rester à peu près **constante**.

Raisnable ✓




bande horizontale

Déraisonnable ✗



« entonnoir » : la variance
augmente avec $\hat{y}$

Déraisonnable ✗




variance plus grande
au centre

En biologie, l'entonnoir est fréquent : les grandes valeurs (concentrations, biomasses, dénombrements) varient souvent davantage.

Exemple 1 : résidus en fonction des valeurs prédites

Diagramme de dispersion des résidus en fonction des valeurs prédites :



Les postulats (P1) et (P2) semblent-ils respectés? **OUI, LES DEUX !**

(P3) Indépendance : difficile à vérifier!

C'est surtout la **collecte des données** qui en est garante : aucune autre variable que X ne doit lier certaines observations entre elles.


Exemples de collectes problématiques :

- plusieurs mesures prises sur le **même individu** (même souris, même plant) comptées comme des observations distinctes;
- des plants cultivés dans le même pot ou sur la même table de la serre, qui partagent lumière, arrosage et température;
- les mesures 1 à 30 prises par une technicienne qui a tendance à surestimer Y, les mesures 31 à 60 par un technicien qui le sous-estime;
- des **données chronologiques** ou spatiales : mesures quotidiennes de la concentration d'un polluant dans une rivière, parcelles voisines d'un champ... les observations rapprochées se ressemblent.

(P3) Données chronologiques

Si les indices $i = 1, \dots, n$ correspondent à l'**ordre de collecte**, le graphique des résidus e_i en fonction de i peut révéler une corrélation entre résidus rapprochés (« effet de grappe »).


Pas d'effet chronologique



signes + et - bien mélangés

INDÉPENDANCE PLAUSIBLE

Effet de grappe



EX. : MESURES
QUOTIDIENNES,
APPAREIL QUI
SE DÉRÈGLE...

résidus de même signe regroupés

**RÉSIDUS VOISINS SE RESSEMBLENT
⇒ DÉPENDANCE (P3)**

(P4) Normalité : histogramme et diagramme quantile-quantile





Diagramme quantile-quantile normal



**HISTOGRAMME : EN CLOCHE, ✓
À PEU PRÈS SYMÉTRIQUE**

**QQ-PLOT : POINTS PRÈS DE LA DROITE ✓
(PETITS ÉCARTS AUX EXTRÉMITÉS : ACCEPTABLE)**

(P4) Test de normalité sur les résidus

Rappel (chapitre 5a) : le test de Shapiro-Wilk teste H_0 : les erreurs suivent une loi normale, contre H_1 : elles ne suivent pas une loi normale.

```
> shapiro.test(residuals(RegModel.1))
```

Shapiro-Wilk normality test

```
data: residuals(RegModel.1)  
W = 0.96941, p-value = 0.1365
```

VALEUR-P = 0,137 > 0,05
⇒ ON NE REJETTE PAS H_0
NORMALITÉ PLAUSIBLE (P4)

Conclusion?

Rappel : avec un grand n , de petits écarts à la normalité deviennent significatifs; avec un petit n , le test a peu de puissance. Les graphiques restent essentiels.

ATTENTION : NE PAS REJETER $H_0 \neq$ PROUVER LA NORMALITÉ.
ON REGARDE AUSSI LES GRAPHIQUES.

QUIZ!


Pour chaque graphique de résidus, quel postulat semble violé (s'il y en a un)?

A (P2) ENTONNOIR


B (P1) ARC

C (P3) GRAPPES


D AUCUN




e_i selon $\hat{y}_i$



e_i selon $\hat{y}_i$



e_i selon l'ordre i



e_i selon l'ordre i


- Pour C et D, les données ont été recueillies une par jour, dans l'ordre i . Pourquoi l'ordre de collecte importe-t-il? **JOURS RAPPROCHÉS $\Rightarrow$ CONDITIONS SEMBLABLES : DÉPENDANCE (P3)**
- Vrai ou faux : si le nuage (x_i, y_i) est bien linéaire, il est inutile de regarder les résidus. **FAUX !**

LES RÉSIDUS RÉVÈLENT MIEUX UNE LÉGÈRE COURBURE, L'ENTONNOIR, LA NON-NORMALITÉ.


Valeurs aberrantes et influentes

Un oiseau fictif (en orange) ajouté aux hirondelles du chapitre 6a. Tirets : droite sans cet oiseau ; trait plein : droite avec cet oiseau.

Valeur **aberrante**: (48; 16,5)



Valeur **influyente**: (70; 9)



- **Aberrante** : très grand résidu ; la pente change peu ($0,328 \rightarrow 0,331$), mais R^2 chute ($0,79 \rightarrow 0,65$).
- **Influente** : x loin des autres ; elle « tire » la droite vers elle (pente $0,328 \rightarrow 0,170$; R^2 : $0,79 \rightarrow 0,33$).

Valeurs aberrantes et influentes : que faire ?

- Toujours **regarder les graphiques** : un seul point peut changer toute la conclusion.
- Vérifier la donnée : erreur de saisie (virgule mal placée, g au lieu de kg)? erreur de mesure? individu d'une autre population (autre espèce, animal malade)?
- Si c'est une erreur, on la corrige (ou on retire la donnée) en le mentionnant.
- Sinon, on **ne retire pas** une donnée simplement parce qu'elle dérange! On peut présenter l'analyse **avec et sans** la donnée et discuter de la différence.

Que faire si les postulats ne sont pas respectés ?

On tente souvent de **transformer** Y et/ou X, puis on refait la régression (et la vérification des postulats!) sur les données transformées.



- **Non-linéarité (P1)** : s'inspirer de la forme du nuage, par exemple

$$\ln(Y_i) = \beta_0 + \beta_1 X_i + \varepsilon_i, \quad Y_i = \beta_0 + \beta_1 \ln(X_i) + \varepsilon_i, \quad Y_i = \beta_0 + \beta_1 X_i^2 + \varepsilon_i.$$

- **Hétéroscédasticité (P2) ou non-normalité (P4)** : une transformation de Y ($\ln Y$, $\sqrt{Y}$) stabilise souvent la variance, surtout quand la dispersion augmente avec la moyenne (entonnoir).
- **Dépendance (P3)** : aucune transformation ne règle le problème; il faut revoir la collecte ou utiliser des modèles qui tiennent compte de la dépendance (hors du cours).
- Autres pistes (hors du cours) : régression polynomiale, régression multiple, modèles non linéaires, méthodes non paramétriques.

Exemple 3 : concentration d'un médicament

On mesure la concentration C (mg/L) d'un médicament dans le sang de 16 patients (un seul prélèvement chacun), $t = 1$ à 12 h après l'injection (données simulées).



Droite : $\hat{C} = 14,17 - 1,264 t$, $R^2 = 0,875$. Les postulats sont-ils respectés ? Que prédit ce modèle à $t = 12$ h ? **(P1) NON RESPECTÉ, (P2) DOUTEUX, $\hat{C} < 0$ (VOIR PAGE SUIVANTE)**

EXEMPLE 3 : LES POSTULATS SONT-ILS RESPECTÉS ?


(P1) : RÉSIDUS EN V (POSITIFS AUX EXTRÉMITÉS, NÉGATIFS AU CENTRE)
⇒ RELATION COURBE, PAS LINÉAIRE.

(P2) : DISPERSION PLUS GRANDE POUR LES FORTES CONCENTRATIONS : DOUTEUX.

À 12 H : $\hat{C} = 14,172 - 1,2639 \times 12 = -1,0 \text{ MG/L}$: IMPOSSIBLE !

EN PHARMACOLOGIE : $C = C_0 E^{-KT}$

⇒ $LNC = LNC_0 - KT$: LINÉAIRE EN T !




Exemple 3 (suite) : transformation logarithmique

$$\widehat{\ln C} = 3,011 - 0,249t$$

$$\Leftrightarrow \hat{C} = e^{3,011} \times e^{-0,249t} = 20,3 \times 0,78^t$$

DÉCROISSANCE EXPONENTIELLE : -22% PAR HEURE



- Droite estimée :
 $\widehat{\ln C} = 3,011 - 0,249 t$, $R^2 = 0,988$;
résidus sans tendance.
- Chaque heure, $\ln C$ diminue de 0,249 : C est multipliée par $e^{-0,249} = 0,78$, i.e. elle diminue d'environ 22 % par heure.
- Prédiction à 12 h :
 $e^{3,011-0,249 \times 12} \approx 1,0$ mg/L (toujours positive).

Les tests et IC portent alors sur le modèle transformé ($\ln C$); on revient à l'échelle d'origine avec e^x .

Réponses aux exemples (1)

- **IC pour la moyenne à 6,5 h** : $\hat{y} = 1,3724 + 0,4313(6,5) = 4,18$; $4,18 \pm 2,00\sqrt{0,3228(1/60 + 1/175)} = 4,18 \pm 0,17$, soit $[4,01; 4,35]$ kg.
- **Précision optimale** en $x^* = \bar{x} = 5,5$ h (le terme $(x^* - \bar{x})^2$ s'annule).
- **Prédiction** : même estimation ponctuelle (4,18 kg), mais erreur-type plus grande; IP à 95 % : $4,18 \pm 2,00\sqrt{0,3228(1 + 1/60 + 1/175)} = 4,18 \pm 1,15$, soit $[3,03; 5,33]$ kg.
- **Quiz (IC ou IP)** : (1) IC pour la moyenne. (2) Intervalle de prédiction. (3) Faux : l'IP tend vers $\pm 1,96 \sigma$ (largeur $\approx 2 \times 1,96 \times 0,568 = 2,2$ kg); c'est l'IC qui tend vers 0. (4) Faux : 7 h est plus loin de $\bar{x} = 5,5$ h que 6,5 h, donc l'IC est plus large.
- $R^2 = SSR/SST = 32,547/51,268 = 0,635$: 63,5 % de la variabilité de la production est expliquée par l'ensoleillement. $R^2 = 0$ si $b_1 = 0$ ($SSR = 0$); $R^2 = 1$ si tous les points sont sur la droite ($SSE = 0$).
- r : $r > 0$ si $b_1 > 0$, $r < 0$ si $b_1 < 0$. Exemple : $r = +\sqrt{0,635} = 0,797$.
- **Quiz (R^2 et r)** : (1) $r = +\sqrt{0,792} = 0,89$; 79 % de la variabilité de l'étendue des ailes est expliquée par le poids. (2) Faux : $|-0,9| > 0,5$, le lien est plus fort (mais négatif). (3) Faux : r ne mesure que le lien *linéaire*; une relation en U peut donner $r \approx 0$. (4) Faux : il faut examiner les résidus (voir l'exemple 3 : $R^2 = 0,875$, mais relation courbe).

Réponses aux exemples (2)

- **Résidus** : donnée 51 : $\hat{y} = 4,82$, $\hat{\varepsilon} = -0,74$.
- **Exemple 1, résidus selon $\hat{y}_i$** : bande horizontale autour de 0, sans tendance ni entonnoir : (P1) et (P2) semblent respectés.
- **Normalité** : histogramme et QQ-plot compatibles avec la normalité ; Shapiro-Wilk : valeur- $p = 0,137 > 0,05$, on ne rejette pas la normalité des erreurs.
- **Quiz (résidus)** : A : (P2), la dispersion augmente avec $\hat{y}$ (entonnoir). B : (P1), les résidus forment un arc (relation courbe). C : (P3), les résidus de même signe sont regroupés (effet de grappe). D : aucun problème apparent. L'ordre importe car des mesures prises à des jours rapprochés peuvent se ressembler (dépendance). Faux : les résidus révèlent mieux une légère courbure, l'hétéroscédasticité ou la non-normalité.
- **Exemple 3** : (P1) n'est pas respecté : résidus en U (positifs aux extrémités, négatifs au centre); (P2) douteux (dispersion plus grande pour les fortes concentrations). À 12 h, $\hat{C} = 14,172 - 1,2639 \times 12 = -1,0$ mg/L : une concentration négative, impossible!