

Chapitre 5 Analyse de la variance

STT-1920 Méthodes statistiques

Véronique Tremblay et Emmanuelle Reny-Nolin

Département de mathématiques et de statistique

Automne 2021

Introduction

Objectifs de l'analyse de la variance (Anova)

- Comparer les **moyennes** d'une variable dans plusieurs populations (normales de même variance);
- Déterminer si un *facteur* (variable discrète ou qualitative) a une influence sur une *variable réponse* (variable aléatoire continue).

variable réponse



PAS cause à effet

(observe-t-on une différence d'un groupe à l'autre?
Est-elle signif. ?)

Exemples

- Un ingénieur aux transports veut comparer la durabilité moyenne de 7 mélanges de peinture pour asphalte.
- Un chercheur développe 3 traitements contre l'hypertension. Il désire savoir si l'un d'entre eux a un délai d'action plus court que les autres.
- Un agronome veut savoir si les 4 variétés de blé qui résistent le mieux à la moisissure donnent des rendements moyens égaux.
- Un directeur de magasin d'appareils électroniques est intéressé à comparer 5 méthodes de publicité. Il veut savoir si ces méthodes sont équivalentes ou si l'une d'elles amène plus de clients que les autres.

ANOVA: Décomposition de la variance

traitement = groupe =
un niveau du facteur = catégorie
= population


L'analyse de variance consiste à identifier et à comparer les **sources de variation** d'une variable:

- la variabilité **inter-traitements** entre les moyennes des échantillons, que l'on associe au facteur (la caractéristique qui distingue les groupes à l'étude).
- la variabilité **intra-traitement** entre les observations d'un même échantillon, que l'on associe à l'erreur échantillonnale (non expliquée par le modèle);

Comparons 2 scénarios

may. sont les
m dans les
2 scénarios
(m effets observés)

Moyennes	Scénario 1	Scénario 2
Traitement A	15.32	15.32
Traitement B	9.61	9.61



plus signif. que le scénario 2

variabilité
inter-traitement
la m dans les
2 scénarios

variab.
intra-traitement
est supérieure
dans scénario
2

Traitement

✕ A
✕ B




Scénario 1: Décomposition de la variance

Totale

=

Inter-
Traitement

(Intra-traitement)
Résiduelle



moy.
globale

variab. entre
les données
et la moy.
globale

(comme si pas de groupes)

variab. entre
les moy. de
traitements
et la
moy. globale.

variabilité
entre les observ.
et leur moy.
de groupe.

Scénario 1: Table d'analyse de la variance

Source de variab $\uparrow$ *Deg. liberté*
sum of squares
carre moyen
val. obs. de la statistique de Fisher
p-value
 $= \frac{MSTR}{MSE} = \frac{65.27}{8.65}$

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Traitement	1	65.27	65.27	7.543	0.0334 *
Residuals	6	51.91	8.65		


 Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

H_0 : toutes les moy sont égales

H_1 : au moins 2 moy.
différent.

Scénario 1
 diff. signif au seuil de 5%.
 H_0 rejetée

Scénario 2: Décomposition de la variance



Scénario 2: Table d'analyse de la variance

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Traitement	1	65.15	65.15	1.484	0.269
Residuals	6	263.45	43.91		

comme dans scénario 1
+ élevé que scénario 1
+ élevé que sc. 1
moins signif (PAS signif)
 H_0 non rejeté

Mathématique de l'ANOVA

But: Comparer les moyennes $\mu_1, \dots, \mu_I$ de la variable Y dans I populations.

$Y_{11}, Y_{12}, \dots, Y_{1n_1}$ ^{$\rightarrow m_1$ obs.} sont issues d'une population $N(\mu_1, \sigma^2)$;

$Y_{21}, Y_{22}, \dots, Y_{2n_2}$ ^{$\rightarrow m_2$ obs} sont issues d'une population $N(\mu_2, \sigma^2)$;

...

$Y_{I1}, Y_{I2}, \dots, Y_{In_I}$ ^{$\rightarrow m_I$ obs} sont issues d'une population $N(\mu_I, \sigma^2)$.


$\downarrow$
centrées
au $\bar{m}$
endroit ?

Hypothèses à confronter

$$Y_{ij} \sim N(\mu_i, \sigma^2) \quad \text{MSE}$$

$$\bar{Y}_{i\cdot} \sim N(\mu_i, \frac{\sigma^2}{n_i}) \quad \text{MSTR}$$

$$H_0 : \mu_1 = \mu_2 = \dots = \mu_I$$




$$MSE \approx MSTR$$

$$F = \frac{MSTR}{MSE} \approx 1$$

$$\sim F_{-, -}$$

H_1 : au moins 2 moyennes différent



$$MSE < MSTR$$

$$F = \frac{MSTR}{MSE} > 1$$

Le modèle à un facteur

$$i = 1, 2, \dots, I$$

$$j = 1, 2, \dots, n_i$$

$$N = n_1 + n_2 + \dots + n_I$$

= nb TOTAL d'obs.

$$Y_{ij} = \mu_i + \varepsilon_{ij} \quad \text{avec} \quad Y_{ij} \sim N(\mu_i, \sigma^2)$$

- μ_i = moy. du i^{e} traitement (dans la i^{e} popul.)
- ε_{ij} = "erreur", déviation, différence entre une obs. et sa moy. de traitement.

Estimation des paramètres:

- μ_i estimé par

$$\bar{y}_{i\cdot} = \text{moy. échant. du trt } i$$

- μ estimé par

$$\bar{y}_{\cdot\cdot} = \text{moy globale de toutes les obs de l'étude.}$$

- σ^2 estimé par

(ligne "Residuals"
dans table ANOVA)

$$MSE = \frac{SSE}{N-I} = \frac{\sum_{i=1}^I \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_{i\cdot})^2}{N-I}$$

$$= \frac{(n_1-1)s_1^2 + (n_2-1)s_2^2 + \dots + (n_I-1)s_I^2}{N-I}$$

Décomposition de la variance

$$SST = SST_R + SSE$$

$$\sum_{i=1}^I \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_{..})^2 = \sum_{i=1}^I n_i (\bar{y}_{i.} - \bar{y}_{..})^2 + \sum_{i=1}^I \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_{i.})^2$$

↑ obs ↑ moy globale
↑ moy. de trait ↑ moy globale
↑ obs ↑ moy de trait

Totale Traitement Résiduelle






Table d'anova

Source de variation	Somme de carrés	Degrés de liberté	Carrés moyens <i>SS / deg.lib</i>	F_{obs}
Traitements (inter-trt)	SST_R +	$I - 1$ +	$MST_R = \frac{SST_R}{I - 1}$	$\frac{MST_R}{MSE}$
Erreur (intra-trt)	SSE 	$N - I$ 	$MSE = \frac{SSE}{N - I}$	
Total	SST	$N - 1$		

dans R
nb de traitements groupes

Nb tot. d'obs

S'il n'y a pas de différence entre les traitements (H_0 est vraie), MST_R et MSE sont tous les deux de bons estimateurs de σ^2 .

Si l'effet des traitements est important, on aura

*S'il y a des différences
entre les moy. théo.*

$$MST_R \gg MSE.$$

À partir de quand considère-t-on que MST_R est vraiment plus grand que MSE ?

Statistique de Fisher

Si

Postulats
ou
conditions
d'application

- les observations sont indépendantes (dans les groupes et entre les groupes)
- les données proviennent d'une distribution normale
- la variance est égale dans chaque groupe

théorique

et que


- H_0 est vraie (μ_i toutes égales)

alors

$$\frac{SST_R/(I-1)}{SSE/(N-I)} = \frac{MST_R}{MSE} \sim F_{I-1, N-I}$$

On rejette H_0 au seuil α si $F_{obs} > F_{I-1, N-I, \alpha}$

Dans ce cas, on aurait un p-value inférieur à α .



Retour au scénario 1

	y1	y2	Traitement
1	14.72	6.3925	A
2	13.52	12.1425	A
3	14.54	20.0725	A
4	18.49	22.6625	A
5	9.98	12.7900	B
6	4.59	2.9100	B
7	12.82	7.1300	B
8	11.03	15.6100	B

$$\bar{y}_{1..} = 15.32$$

$$\bar{y}_{2..} = 9.61$$

$$\begin{aligned} SST_R &= \sum_i n_i (\bar{y}_{i..} - \bar{y}_{..})^2 \\ &= 4(15.32 - 12.465)^2 + 4(9.61 - 12.465)^2 \\ &= 65.27 \end{aligned}$$

$$\begin{aligned} MSE &= \sum (n_i - 1) s_i^2 / N - I \\ &= \frac{(4-1) 2.18^2 + (4-1) 3.54^2}{8-2} \\ &= 8.65 \end{aligned}$$

A1moy	A1s	B1moy	B1s
15.32	2.18	9.61	3.54

moy globale $\bar{y}_{..} = \frac{4 \cdot 15.32 + 4 \cdot 9.61}{8} = 12.465$

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Traitement	I-1=1	65.27	65.27	7.543	0.0334 *
Residuals	N-I=6	51.91	8.65		

$$\rightarrow \frac{65.27}{8}$$

Aurait-on pu faire un test de Student?

ANOVA

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Traitement	1	65.27	65.27	7.543	0.0334 *
Residuals	6	51.91	8.65		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Test de student

Two Sample t-test

data: y1 by Traitement

t = 2.7464, df = 6, p-value = 0.03345

alternative hypothesis: true difference in means between group A and group B
95 percent confidence interval:

0.6230128 10.8019872

sample estimates:

mean in group A	mean in group B
15.3175	9.6050

Student vs ANOVA

- Est-ce que c'est un hasard si les p-valeurs sont les mêmes?

Non. $\hat{M}$ contexte ($\hat{m}$ postulats $\rightarrow$ Loi N
 $\rightarrow$ var. =
 $\rightarrow$ échant. indep)

$$t_{\text{obs}}^2 = F \text{ si j'ai } I=2. \quad (\text{Ici : } (2.75)^2 = 7.54)$$

- Pourquoi faire l'ANOVA?

c'est une extension à $I \geq 2$

Exemple: agent de conservation naturel pour la viande, à partir de sang de porc

<https://nouvelles.ulaval.ca/recherche/de-residu-a-source-dagents-de-conservation-naturels-0797d4c252cd98ac53f75a256e95624a?sourceOrganizationKey=ulaval>


- «Indeed, in 2016, 30 million litres of bovine and porcine blood were produced in the Quebec province.» (dans l'article)
- Une nouvelle méthode d'extraction (EDUF) permet une plus grande concentration de peptides bioactifs.
- «Les tests que nous avons effectués sur du bœuf haché ont révélé que ces extraits [de sang] sont aussi efficaces que le BHT, un additif chimique couramment utilisé par l'industrie alimentaire.» (sur le site de l'Université)

Nous avons simulé des données à partir des moyennes et écarts-types de la section 3.6 de l'article.

Contexte

- On veut comparer l'effet antioxydant de l'EDUF (la nouvelle méthode) au peptide original nommé " α 137 – 141" et à un contrôle.
- On crée un échantillon de taille 6 pour chaque traitement
- On mesure le TBARS (en mg MDA/kg de viande hachée) après 4 jours (une mesure de rancissement)

Test ANOVA



1. Hypothèses

H_0 : Les trois moyennes sont égales

H_1 : Au moins une moyenne est différente d'une autre

2. Choix du test et définition de la zone de rejet

Si les données sont distribuées normalement et que les variances sont égales, on fait une analyse de variance à un facteur.

On choisit α . On rejette H_0 si la p-valeur est inférieure à α .

Choisissons arbitrairement $\alpha = 0,05$.

On rejette H_0 si $F_{obs} > 3.682 = F_{2,15; 0.05}$

Test ANOVA

3. On fait le test avec un logiciel





Table d'anova à compléter



② $0,2971 - 0,156$
 $SST = SSTR + SSE$
 $= SST$

③ $MSTR = \frac{SSTR}{2}$

④ $MSE = \frac{SSE}{15}$
 $0,0104 \times 15$

Source de variation	Somme de carrés	Degrés de liberté	Carrés moyens	F_{obs}
Traitements (inter-trt)	0,1411	2 (3-1)	0,0706	6,78
Erreur (intra-trt)	0,156	15 (18-3)	0,0104 $= MSE = \hat{\sigma}^2$	
Total	0,2971	17 (18-1)		

Sortie R

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Traitement	2	0.1412	0.0706	6.791	0.00794 **
Residuals	15	0.1559	0.0104		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

4. Décision

On rej. H_0 $\leftarrow$ car le $p\text{-val} = 0.00794 < 0,05 = \alpha$
 $F_{obs} > F_{critique}$.

5. Conclusion

Il y a au moins 2 produits dont l'effet anti-rancissement est différents.

Lesquels?

Test de comparaisons
2 à 2

Contrastes

- Comment savoir quelles moyennes sont différentes? (section 5.8)

"Comparaisons 2 à 2"

- Peut-on simplement faire plusieurs tests de Student 2 à 2?

Oui. Car le seuil global est protégé par le test de Fisher

Simultaneous Tests for General Linear Hypotheses

Multiple Comparisons of Means: Tukey Contrasts

très similaire à des tests de Student 2 à 2


Fit: aov(formula = TBARS ~ Traitement, data = conservation)


Linear Hypotheses:

	Estimate	Std. Error	t value	Pr(> t)
Controle - a137_141 == 0	0.21658	0.05887	3.679	0.00599 **
EDUF - a137_141 == 0	0.09732	0.05887	1.653	0.25496
EDUF - Controle == 0	-0.11926	0.05887	-2.026	0.14031

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Adjusted p values reported -- single-step method)





Vérification des postulats

Indépendance des observations: Structure de l'expérience

- Y a-t-il des liens entre les observations d'un même traitement?
de traitements différents?
- A-t-on pris plusieurs mesures sur une même unité
expérimentale?

Homogénéité des variances: Test de Bartlett

On veut tester les hypothèses:


$$H_0 : \sigma_1^2 = \sigma_2^2 = \dots = \sigma_I^2$$

H_1 : au moins 2 de ces variances sont inégales

On utilise une statistique B (appelée K-squared dans R-Commander):

- Si H_0 est vraie, B suit une loi χ^2_{I-1} .
- Si H_1 est vraie, B prendra des valeurs plus élevées que celles attendues sous la χ^2_{I-1} .
- Alors au seuil α , on rejette l'égalité des variances si...

$$B_{\text{obs}} = \text{K-squared}_{\text{obs}} > \chi^2_{I-1, \alpha}.$$




$$B = \frac{(N - I) \ln(MSE) - \sum_{i=1}^I (n_i - 1) \ln(S_i^2)}{1 + \frac{1}{3(I-1)} \left\{ \left(\sum_{i=1}^I \frac{1}{n_i-1} \right) - \frac{1}{N-I} \right\}}.$$

Exemple

Bartlett test of homogeneity of variances

data: TBARS by Traitement

Bartlett's K-squared = 0.74383, df = 2, p-value = 0.6894



H_0 non rejetée
Les variances théoriques sont
considérées égales.

Vérification de la normalité des observations: Analyse des résidus = estimation des erreurs théoriques $Y_{ij} - \mu_i$

Rappel du modèle:

$$Y_{ij} = \mu_i + \varepsilon_{ij}$$

Puisque $Y_{ij} \sim N(\mu_i, \sigma^2)$, il suit que $\varepsilon_{ij} \sim N(0, \sigma^2)$.

Les erreurs échantillonales, ε_{ij} , sont estimées par les **résidus** du modèle:

$$\hat{\varepsilon}_{ij} = y_{ij} - \overline{y_{i\bullet}}$$

$\downarrow$ obs $\downarrow$ moy. de trait.

Au lieu d'analyser directement les observations, nous analyserons les résidus.

But: translaten toutes les "cloches" pour les centrer en 0.
Ainsi, on fera UN SEUL TEST au lieu de 3 tests.

Test de normalité sur les résidus


$W \approx 1$ H_0 : loi N est un bon modèle
 $W \ll 1$ H_1 : " n'est pas "

Shapiro-Wilk normality test

data: AnovaModel.3\$residuals

W = 0.97151, p-value = 0.8255


$\Rightarrow H_0$ non rejetée
la dist. Normale
est acceptée comme
modèle



→ hist. et diag QQ des résidus


Normal Q-Q Plot

Sample Quantiles = Résidus



Theoretical Quantiles $\Rightarrow$ quantiles Z

Histogram of AnovaModel.3\$residuals



Si les postulats 2 ou 3 (var =, loi N)
ne sont pas respectés

→ Transformer Y

$$\Rightarrow \sqrt{Y}$$

$$\Rightarrow \ln(Y)$$

$$\Rightarrow \frac{1}{Y}$$

$$\Rightarrow Y^2$$

$$\Rightarrow e^Y$$

} refaire l'anova
recalculer résidus
révérifier postulats.

→ Test de Kruskal-Wallis: anova basée
sur les rangs