

qu'une dizaine de classes est le nombre permettant la meilleure étude statistique; ces classes doivent, naturellement, être d'égale étendue.

b) Diagrammes de fréquences

De plus en plus, dans les publications, les chercheurs biologistes remplacent les tableaux de chiffres dont la lecture est le plus souvent malaisée par des diagrammes ou des graphiques qui ont l'avantage de faire apparaître immédiatement les caractéristiques générales d'une distribution ou l'allure d'un phénomène.

c) Paramètres d'une distribution

Comme *paramètre de position*, la moyenne arithmétique des résultats $\frac{\sum x}{n}$ est généralement utilisée. Dans certains cas, on calcule aussi la médiane et le mode lorsque la distribution de fréquences est particulièrement asymétrique.

Comme *paramètre de dispersion*, les *quantiles* (on utilisait beaucoup autrefois les *quartiles*) et l'écart moyen arithmétique $\frac{\sum (x - X)}{n}$ ne sont plus guère usités. Par contre, la notion de *variance* $\nu = \frac{\sum (x - X)^2}{n - 1}$ et d'*écart-type* ou écart quadratique moyen $\sigma = \sqrt{\nu}$ sont très généralement employés. Les valeurs moyennes des résultats expérimentaux sont en général accompagnées de l'*erreur standard* : $\frac{\sigma}{\sqrt{n}}$. La détermination du *coefficient de variation* c'est-à-dire du rapport de l'écart-type à la moyenne $V = \frac{100 \sigma}{m}$ p. 100 peut quelquefois être utile. Il permet, en effet, de comparer la dispersion de diverses distributions étant donné qu'il est indépendant des unités employées pour mesurer les variations.

II — Principales distributions des résultats biologiques

a) Distribution binomiale

Elle est obtenue en représentant les termes successifs du développement du binôme $(p + q)^n$ avec $p + q = 1$. On rencontre des distributions de ce genre en biologie quand la fréquence d'un événement a une probabilité constante. Ce fait se produit en génétique : si on examine la fréquence d'apparition en première génération d'un caractère récessif, les lois de MANDEL prévoient une probabilité de 0,25. Il en est de même pour la détermination du sexe : mâles et femelles apparaissent avec une probabilité approximativement égale; dans ce dernier cas, la distribution est symétrique.

b) Distribution de POISSON


C'est une limite de la distribution précédente lorsque la probabilité d'un événement devient très petite (1/100 par exemple); ce cas se rencontre assez souvent en biologie. En hématologie, certains éléments figurés se trouvent en faibles proportions dans le sang. Ainsi, la probabilité de rencontrer un polynucléaire eosinophile par rapport au nombre total de leucocytes n'est que de 1 %. L'éventualité la plus probable est donc que, pour une numération globulaire portant sur 100 éléments, il y ait un seul eosinophile. La représentation de fréquences après n déterminations de ce genre se traduit par une distribution de Poisson.

Le même genre de distribution se rencontre en génétique si on compte le nombre de mutants dans divers échantillons d'une population (la fréquence des mutations est en effet très faible). De même, les résultats d'une numération bactérienne par la méthode de dilution s'expriment aussi selon une distribution de POISSON. La formule mathématique d'une telle distribution est : $y = \frac{m}{r!} e^{-m}$.

c) *Distribution normale ou de GAUSS-LAPLACE*

On obtient une distribution de ce genre quand une grandeur subit l'influence d'un grand nombre de causes de variations petites et indépendantes les unes des autres. C'est ce phénomène qui se produit le plus souvent en biologie, la dispersion biologique étant le résultat d'un nombre considérable de causes de variation. Effectivement, dans la grande majorité des cas, les courbes de fréquences des résultats obtenus dans l'expérimentation biologique se rapprochent de la courbe normale.

Sa formule mathématique est : $y = \frac{1}{\sigma \sqrt{2\pi}} \cdot e^{-\frac{(x-m)^2}{2\sigma^2}}$ et ne comporte comme paramètres que la moyenne arithmétique m et l'écart-type σ . Ce sont deux valeurs faciles à estimer à partir des résultats expérimentaux. Cette courbe est symétrique (Graphique V),



GRAPHIQUE V : Distribution normale

les points d'inflexion correspondant à $x = m \pm \sigma$. L'aire comprise entre la courbe, l'axe des abscisses et les deux verticales élevées aux points $m \pm n\sigma$ est une fraction de l'aire totale. L'intervalle $(-\sigma, +\sigma)$ autour de la moyenne correspond à 68 % de cette aire et l'intervalle $(-2\sigma, +2\sigma)$ à 95 %. Ceci veut dire que, si on tire, au hasard, le résultat d'une mesure dans un ensemble de résultats répondant à cette loi, il y a une probabilité de 95 %

pour qu'elle ne s'écarte de la moyenne que d'une valeur inférieure à deux fois l'écart-type; 5 % seulement des résultats ne sont pas compris dans l'intervalle $(-2\sigma, +2\sigma)$. En biologie, on admet, en général, que l'intervalle $\pm 2\sigma$ autour de la moyenne est un intervalle de sécurité suffisant : on prend un risque de 5 %. Le seuil de signification généralement admis est 95 %, plus rarement 99 % quand il s'agit de déterminations biochimiques à faible variation. Dans ces conditions, l'estimation d'une moyenne est exprimée de la manière suivante :

$X = m \pm \frac{2\sigma}{\sqrt{n}}$ (m étant la moyenne, σ l'écart type et n le nombre d'expériences). Ceci n'est

valable que si le nombre de déterminations est suffisamment grand; il peut se produire, cependant, que l'expérimentateur soit obligé de limiter ses épreuves étant donné le prix élevé du matériel animal (singes Rhésus, gros animaux domestiques) ou sa rareté (chien). Dans le cas où l'échantillon est inférieur à 25 ou 30 individus, il est nécessaire de tenir compte de l'erreur commise sur l'estimation de l'écart-type et d'utiliser le facteur de correction « t »

de STUDENT. La valeur moyenne sera alors exprimée par $X = m \pm t_p \frac{\sigma}{\sqrt{n}}$ (la valeur de t_p

est donnée par les tables de STUDENT en fonction de la probabilité d'erreur et du degré de liberté) (1).

D — INTERPRÉTATION DES RÉSULTATS

Après avoir déterminé la valeur moyenne des résultats, le biologiste se trouve souvent dans l'obligation, soit de comparer entre elles deux distributions, soit de vérifier si une distribution est conforme à une hypothèse ou à une loi déjà formulée. Les statistiques lui procurent pour cela un certain nombre de tests de signification que nous allons maintenant examiner.

1) Tests de signification

a) Comparaison d'une moyenne expérimentale et d'une valeur théorique

Il suffit de déterminer si la valeur théorique est comprise dans l'intervalle de confiance que nous avons calculé pour la variable expérimentale.

b) Comparaison d'une distribution expérimentale et d'une distribution théorique

Ceci se produit fréquemment en génétique quand on doit vérifier si une population obéit aux lois de MANDEL. On utilise, dans ce cas, le test du X^2 de PEARSON.

c) Comparaison de deux moyennes expérimentales

Ce problème se pose de façon très générale en biologie; lorsqu'on veut, par exemple, étudier l'action d'une substance ou d'une intervention sur une constante biologique, il est indispensable de comparer les résultats moyens obtenus sur deux séries d'animaux, les uns ayant reçu l'intervention, les autres étant des animaux normaux servant de témoins. On peut, aussi, avoir à comparer les actions respectives de deux doses différentes d'une même substance. Pour résoudre ce problème, on compare les deux valeurs moyennes et les deux

variances par la méthode du test de « t » de STUDENT : $t = \frac{m_1 + m_2}{\sqrt{\sigma_0^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}}$, σ_0 étant la

(1) FISHER and YATES, *Statistical Tables of Biological, Agricultural and Medical Research* (Oliver et Boyd. Ltd, Edinburgh).